

# Statistiques non paramétriques

## I - From histogram to Kernel density estimation

What is a probab density?

$$P(X \in B) = \int_B dP_X$$

$$\begin{aligned} \text{thm. dis. measures} &= \int_B f(x) d\lambda(x) \quad \forall B \in \mathcal{B}_{\mathbb{R}}. \\ \text{finis. } \int &\approx f(x) \text{vol}(B). \end{aligned}$$

Hence, for  $B_j = (x_0 + jh, x_0 + (j+1)h]$

$$P(X \in B_j) = f(x) \times h$$

$$\Rightarrow f(x) = \frac{P(X \in B_j)}{h}$$

$$\begin{aligned} \Rightarrow \tilde{f}(x) &= \frac{1}{h} \times \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{X_i \in B_j\}} \quad \forall x \in B_j \\ &= \frac{1}{nh} \sum_{i=1}^n \mathbb{1}_{B_j}(X_i) \mathbb{1}_{B_j}(x) \end{aligned}$$

$$\begin{aligned} \text{MISE}(h) &\triangleq \mathbb{E} \left[ \int (\tilde{f}_n(x) - f(x))^2 dx \right] \quad \text{Fubini} \\ &= \int \mathbb{E} [(\tilde{f}_n(x) - f(x))^2] dx \\ &= \int \text{MSE}(\tilde{f}_n(x)) dx \\ &= \int \mathbb{B}^2(\tilde{f}_n(x)) + \text{Var}(\tilde{f}_n(x)) dx \end{aligned}$$

$$\text{Or } B(f_n^v(x)) = \mathbb{E}[f_n^v(x)] - f(x).$$

$$\begin{aligned} Z_{0,1}(x) &\sim B(n, p_j) \quad G = \frac{1}{h} B - f(x) \\ &= \frac{1}{h} \int_B f(t) dt - f(x) \\ &= \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} f(t) dt - f(x) \\ &= \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} f(x) + (t-x)f'(x) \\ &\quad + \frac{(t-x)^2}{2} f''(x) dt - f(x) \\ f(x) &= f(x-zt) \\ z &\in [0,1] \end{aligned}$$

$$\begin{aligned} &= \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} (t-x)f'(x) + \frac{(t-x)^2}{2} f''(x) dt \\ &= \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} (t-x)f'(x) dt \\ &\quad + \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} \frac{(t-x)^2}{2} f''(x) dt \\ &= \frac{f'(x)}{h} \int_{x_0+jh}^{x_0+(j+1)h} t dt - x \frac{f'(x)}{h} \int_{x_0+jh}^{x_0+(j+1)h} dt \\ &\quad + \mathcal{O}(h^2) \end{aligned}$$

$$\begin{aligned} x f'(x) \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} dt &= \frac{1}{h} h = 1 \times f'(x) \times x \\ f'(x) \frac{1}{h} \int_{x_0+jh}^{x_0+(j+1)h} t dt &= \left[ \frac{t^2}{2} \right]_{x_0+jh}^{x_0+(j+1)h} = \frac{1}{h} \left( \frac{(j+1)^2 h^2}{2} - \frac{(jh)^2}{2} \right) \\ &= \frac{h}{2} ((j+1)^2 - j^2) = \frac{h}{2} (j^2 + 2j + 1 - j^2) (f'(x)) \\ &= \frac{h}{2} (2j+1) f'(x) \end{aligned}$$

$$\begin{aligned} &= f'(x) \left( h \left( j + \frac{1}{2} \right) \right) - f'(x) x + \mathcal{O}(h^2) \\ &= f'(x) \left( h \left( j + \frac{1}{2} \right) - x \right) + \mathcal{O}(h^2) \\ &= \mathcal{O}(h) + \mathcal{O}(h^2) \\ &= \mathcal{O}(h) \end{aligned}$$

$$\begin{aligned} \mathcal{O}(h) &\equiv \mathcal{O}(h^1) \\ \frac{h}{h^2} &= \frac{1}{h} \xrightarrow{h \rightarrow \infty} \text{four} \end{aligned}$$

$$\begin{aligned} \text{main } \mathcal{O}(h^2) &= \mathcal{O}(h^2) \\ \frac{h^2}{h} &\rightarrow 0 \text{ main} \end{aligned}$$

$$V(P_n^v(x)) = \frac{1}{nh^2} P_1(1-P_1) \quad (1)$$

Comme  $P(P_n^v(x)) = \frac{1}{h} P_1 - P_1(1) = O(h)$

$$\Leftrightarrow \frac{1}{h} P_1 = f(x) + O(h).$$

$$(1) = \frac{1}{nh} \left( \frac{P_1}{h} \right) - \frac{1}{n} \left( \frac{P_1}{h} \right)^2$$

$$= \frac{1}{nh} \left( f(x) + O(h) \right) - \frac{1}{n} \left( f(x) + O(h) \right)^2$$

$$= \frac{1}{nh} f(x) + O\left(\frac{1}{n}\right) - \frac{1}{n} f^2(x) - O\left(\frac{1}{n}\right).$$

$$O\left(\frac{1}{n}\right) = O\left(\frac{1}{n}\right)$$

car  $\frac{1}{nh} \xrightarrow[n \rightarrow \infty]{} 0$

$$= \frac{1}{nh} f(x) - \frac{1}{n} f^2(x) + O\left(\frac{1}{n}\right).$$

$$= \frac{1}{nh} f(x) - O\left(\frac{1}{n}\right)$$

$$= O\left(\frac{1}{nh}\right).$$

car cela ne dépend pas de  $h$ .

$$O\left(\frac{1}{n}\right) = O\left(\frac{1}{nh}\right)$$

car  $\frac{1}{nh} = \frac{1}{n} \times nh = h \rightarrow 0$

$$\Rightarrow O\left(\frac{1}{n}\right) = O\left(\frac{1}{nh}\right) = O\left(\frac{1}{nh}\right).$$

Rappel :  $MISE(h) = \int B^2(p_n^{\sim}(x)) + var(p_n(x)) dx$ .

avec  $B(p_n^{\sim}(x)) = f'(x) \left( h(j+\frac{1}{2}) - x \right) + O(h^2)$ .

$\Rightarrow B^2(p_n^{\sim}(x)) = f'^2(x) \left( h(j+\frac{1}{2}) - x \right)^2 + O(h^3)$ .

$m$  subdivision on  $[0, 1]$   $\Rightarrow \Omega = \bigcup_{j=0}^{m-1} B_j \Rightarrow \int_a b dp = \sum_{j=0}^{m-1} \int_{B_j} b dp$   
avec  $B_j = (jh, (j+1)h)$

$\Rightarrow \int_0^1 B^2(p_n^{\sim}(x)) dx = \sum_{j=0}^{m-1} \int_{B_j} B^2(p_n^{\sim}(x)) dx$

$\xrightarrow{h \rightarrow 0} x \approx jh, jh+h$

$$\begin{aligned} &= \sum_{j=0}^{m-1} \int_{jh}^{(j+1)h} f'^2(x) \left( h(j+\frac{1}{2}) - x \right)^2 + O(h^3) \\ &= \sum_{j=0}^{m-1} \int_{jh}^{(j+1)h} f'^2(jh) \left( h(j+\frac{1}{2}) - x \right)^2 + O(h^3) \\ &= \sum_{j=0}^{m-1} f'^2(jh) \int_{jh}^{(j+1)h} \left( h(j+\frac{1}{2}) - x \right)^2 + O(h^3) \\ &= \sum_{j=0}^{m-1} f'^2(jh) \int_{-\frac{h}{2}}^{\frac{h}{2}} y^2 dx + O(h^3) \end{aligned}$$

$y$  change de var

$$= \frac{h^3}{12} \sum_{j=0}^{m-1} f'^2(jh) + O(h^3)$$

$h = \int_{jh}^{(j+1)h} dx$

$$\begin{aligned} &= \frac{h^2}{12} \sum_{j=0}^{m-1} f'^2(jh) + O(h^3) \\ &= \frac{h^2}{12} \sum_{j=0}^{m-1} \int_{jh}^{(j+1)h} f'^2(jh) + O(h^3) \\ &= \frac{h^2}{12} \sum_{j=0}^{m-1} \int_{jh}^{(j+1)h} f'^2(x) dx + O(h^3) \\ &= \frac{h^2}{12} \int_0^1 f'^2(x) dx + O(h^3) \end{aligned}$$

On ne va pas plus loin car on a un polynôme de degré 2.

De même,  $\text{Var}(\tilde{f}_n(x)) = \frac{f(x)}{nh} + O(\frac{1}{n})$

$$\Rightarrow \int_0^1 \text{Var}(\tilde{f}_n(x)) dx = \int_0^1 \frac{f(x)}{nh} + O(\frac{1}{n}) dx$$

une intégrale  $\Rightarrow \frac{1}{nh} + O(\frac{1}{n})$

$$\Rightarrow \text{MISE}(h) = \frac{h^2}{12} \int_0^1 f''^2(x) dx + \frac{1}{nh} + O(\frac{1}{n}) + O(h^2)$$

Le terme dominant du biais provient de :

$$\frac{f'(x)}{h} \int_{jh}^{(j+1)h} (t-x) dt$$

Il est toutefois possible de réduire le biais en modifiant  $B_j$  par un intervalle centré en  $x$ .

$$t: x \in [jh, (j+1)h] \rightarrow t: x \in [x-h, x+h]$$

$$\begin{aligned} \Rightarrow \frac{1}{h} \int_{jh}^{(j+1)h} (t-x) dt &\rightarrow \frac{1}{2h} \int_{x-h}^{x+h} (t-x) dt \quad \left. \begin{array}{l} \\ \end{array} \right\} u = t-x \\ &= h \int_{-1}^1 \frac{u}{2} \mathbb{I}_{[-1,1]}(u) du \\ &\quad \underbrace{\qquad\qquad\qquad}_{K(u) \rightarrow \text{Box kernel}} \end{aligned}$$

How to choose  $h$  in practice?

$$\text{MISE}(h) = E[\| \tilde{f}_n - f \|^2]$$

$$\hookrightarrow E[\langle \cdot, \cdot \rangle] = \int f(x) f(x) dx$$

$$= E[\| \tilde{f}_n \|^2] - 2 E[\langle \tilde{f}_n, f \rangle] + E[\| f \|^2]$$

$$= E[\| \tilde{f}_n \|^2] - 2 E[\langle \tilde{f}_n \rangle] + \| f \|^2$$

$$\arg \min_{( \| f \|^2 = \int f^2 dx )} \text{MISE}(h) \Rightarrow \arg \min E[\| \tilde{f}_n \|^2] - 2 E[\langle \tilde{f}_n \rangle] \quad \underbrace{\qquad\qquad\qquad}_{\text{MISE}(h) - \| f \|^2}$$

Un estimateur de  $MSE(h) = \|f\|^2$

$$CV(h) = E[\|f_n^{\sim}\|^2] - 2E[f_n^{\sim}(x)]$$

$$\text{est } E[\|f_n^{\sim}\|^2] - 2E[f_n^{\sim}(x)] = \|f_n^{\sim}\|^2 - \frac{2}{n} \sum_{i=1}^n f_n^{\sim(-1)}(x_i)$$

$$\text{avec } f_n^{\sim(-1)}(x) = \frac{1}{(n-1)h} \sum_{j \neq i} \sum_{k=1}^n \mathbb{I}_{B_j}(x) \mathbb{I}_{B_j}(x_k)$$

$$E[f_n^{\sim}(x)] = E[f_n^{\sim(-1)}(x_i)] = \frac{1}{n} \sum_{j=1}^n \hat{\beta}_j^2$$

$$E[CV(h)] = MSE(h) - \|f\|^2$$

$$CV(h) = \frac{2}{(n-1)h} - \frac{n+1}{(n-1)h} \sum_{j=1}^n \hat{\beta}_j^2$$

$$\text{avec } \hat{\beta}_j = \frac{1}{n} \sum_{i=1}^n \mathbb{I}_{B_j}(x_i).$$

Si  $f$  est continue,  $h_n \rightarrow 0$  and  $nh_n \rightarrow \infty$ , alors

$$\tilde{f}_n(x) \xrightarrow[n \rightarrow \infty]{L^2} f(x) \quad \left\{ \begin{array}{l} h_n \rightarrow 0 \Rightarrow \beta(f_n^{\sim}(x)) \rightarrow 0 \\ nh_n \rightarrow \infty \Rightarrow v(f_n^{\sim}(x)) \rightarrow 0 \end{array} \right.$$

## II- Kernel Density Estimator

### 1/ Cas univarié

Convolution product :  $\gamma(z) = f * g(z)$

$$= \int_{\mathbb{R}} f(z-u) g(u) du$$

$$= \int_{\mathbb{R}} f(u) g(z-u) du$$

Parzen-Rosenblatt (KDE)

$$f_n^{\sim}(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right) = \frac{1}{n} \sum_{i=1}^n K(x-x_i)$$

$$\text{avec } K(x-x) = \frac{1}{h} K\left(\frac{x-x}{h}\right).$$

$$\mathbb{E}[f_n(x)] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n K_n(x-x_i)\right]$$

$$= \mathbb{E}[K_n(x-X)]$$

$$= \int K_n(x-x) f(x) dx$$

$$= (K_n * f)(x)$$

$$V(f_n(x)) = V\left(\frac{1}{n} \sum_{i=1}^n K\left(\frac{x-x_i}{n}\right)\right)$$

$$= \frac{1}{n^2} \sum_{i=1}^n V\left(K\left(\frac{x-x_i}{n}\right)\right)$$

$$= \frac{1}{n^2} V\left(K\left(\frac{x-X}{n}\right)\right)$$

$$= \frac{1}{n^2} \left\{ \mathbb{E}\left[K^2\left(\frac{x-X}{n}\right)\right] - \mathbb{E}\left[K\left(\frac{x-X}{n}\right)\right]^2 \right\}$$

$$\begin{aligned} k(\cdot) &= K^2(\cdot) \\ \Rightarrow k(\cdot) &= K_n^2(\cdot) \\ &= \frac{1}{n} K\left(\frac{x-X}{n}\right) \end{aligned} \quad \int \quad \begin{aligned} &= \frac{1}{n^2} \mathbb{E}\left[K_n^2(x-X)\right] - \frac{1}{n^2} \mathbb{E}\left[K(x-X)\right]^2 \\ &= \frac{1}{n^2} \left( (k_n * f)(x) - \frac{1}{n} (K_n * f)^2(x) \right) \end{aligned}$$

Lemme Bochner, attention aux bornes.

Si  $f$  continue sur  $\mathbb{R}$  et bornée,  $K$  intégrable

sur  $\mathbb{R}$ . Alors,

$$\lim_{n \rightarrow \infty} (K_n * f)(x) = f(x) \int K(u) du.$$

Preuve

$$(K_n * f)(x) = \int K_n(x-u) f(u) du = \int \frac{1}{n} K\left(\frac{x-u}{n}\right) f(u) du$$

$$y = \frac{x-u}{n}.$$

$$\stackrel{\text{changement de variable}}{=} \int \frac{1}{n} K(u) f(x-nu) |n| du = \int K(u) f(x-nu) du$$

Conv. dominée :

$$\left. \begin{array}{l} f(x-hu) \xrightarrow{h \rightarrow 0} f(x) \\ |K(u)f(x-hu)| \leq \sup K(u) \end{array} \right\} \int K(u)f(x+hu) du \xrightarrow{h \rightarrow 0} f(x) \int K(u) du$$

$$\rightarrow (K_R * f)(x) = \int K(u)f(x+hu) du = f(x) \int K(u) du + o(1)$$

le biais de  $\hat{f}_n(x)$  est :

si  $f \in \mathcal{C}^2$ ,  $f'$  borné et  $K$  noyau symétrique.

$$B(\hat{f}_n(x)) = E[\hat{f}_n(x)] - f(x)$$

$$\text{Biais } \hat{f}_n = (K_R * f)(x) - f(x).$$

$$\text{Si } \int K(u) du = 1 \quad \text{d } h \rightarrow 0 \quad \begin{cases} \hat{f}_n = f(x) \int K(u) du + o(1) - f(x) \\ = o(1) \end{cases}$$

$(\Rightarrow \hat{f}_n(x)$  est asymptotiquement sans biais)

$$\begin{aligned} &= \int K_h(x-u)f(u) du - f(x) \\ &= \int \frac{1}{h} K\left(\frac{x-u}{h}\right) f(u) du - f(x) \\ &= \int K(u) f(x-hu) du - f(x) \\ &= \int K(u) \left\{ f(x) + (-hu)f'(x) + \frac{(-hu)^2}{2} f''(x) + o(h^2) \right\} du - f(x) \\ &= -h f'(x) \int u K(u) du + \frac{h^2}{2} f''(x) \int u^2 K(u) du + o(h^2) \\ &= \frac{h^2}{2} f''(x) \int u^2 K(u) du + o(h^2) = O(h^2) \end{aligned}$$

$K$  a kernel of order 2.



De même, (si  $f$  est borné et continue au vois. de  $x$ )

$$V(f_n^*(x)) = \frac{1}{nh} (k_h * f)(x) - \frac{1}{n} (K_h * f)^2(x)$$

si  $K^2$  est intégrable <sup>Bachman</sup>  
 $K$  est de carré intégrable

$$= \frac{1}{nh} \left[ f(x) \int K^2(u) du + o(1) \right] - \frac{1}{n} [f(x) + o(1)]$$

$$= \frac{1}{nh} f(x) \int K^2(u) du + o\left(\frac{1}{nh}\right) + o\left(\frac{1}{n}\right)$$

$$= \frac{1}{nh} f(x) \int K^2(u) du + o\left(\frac{1}{nh}\right)$$

$$= \mathcal{O}\left(\frac{1}{nh}\right) \Rightarrow \frac{1}{nh} \xrightarrow{n \rightarrow \infty} 0 \Rightarrow \mathcal{O}\left(\frac{1}{nh}\right) = o(1) = \mathcal{O}(1)$$

Ainsi si  $h_n \xrightarrow{n \rightarrow \infty} 0$  et  $nh_n \xrightarrow{n \rightarrow \infty} +\infty$  et  $\int K^2(u) du < \infty$   
 alors  $f_n^*(x) \xrightarrow[n \rightarrow \infty]{P} f(x)$ . consistant estimateur  
 si  $h_n \rightarrow 0$ ,  $B(f_n^*(x)) = o(1)$  } asymptotiquement  
 sans biais  
 si  $nh_n \rightarrow \infty$ ,  $V(f_n^*(x)) = o(1)$

MSE.

(A)  $K$  un noyau symétrique tq  $\int |K^2(u)| du < +\infty$   
 $\int u^2 K(u) du \neq 0$

$f \in \mathcal{C}^2$  sur  $\mathbb{R}$  avec  $f(x) > 0$ ,  $f''(x)$  bornée  $\neq 0$  sur  $\mathbb{R}$   
 Alors,  $MSE = E[(f_n^*(x) - f(x))^2] = B^2(f_n^*(x)) + V(f_n^*(x))$

$$= \frac{f(x)}{nh} \int K^2(u) du + \frac{h^4}{4} f''(x) \int u^2 K(u) du + o(h^2) + o\left(\frac{1}{nh}\right)$$

$\Rightarrow MSE \rightarrow 0$   
 when  $h \rightarrow 0$   
 $nh \rightarrow \infty$

$$= \left( \frac{f(x)}{nh} \int K^2(u) du + \frac{h^4}{4} f''(x) \int u^2 K(u) du \right) (1 + o(1))$$

## MISE

Si (A) et  $f'$  existe et est absolument continue sur  $\mathbb{R}$  et  $\int (f''(x))^2 dx < +\infty$ . ( $f''^2$  intégrable)  
Alors,

$$\begin{aligned} \text{MISE}(h) &= \mathbb{E} \left[ \int (\hat{f}_n(x) - f(x))^2 dx \right] = \int \mathbb{E} \left[ (\hat{f}_n(x) - f(x))^2 \right] dx \\ &= \left( \frac{1}{nh} \int K^2(u) du + \frac{h^4}{4} \int u^2 K(u) du \int f''(x)^2 dx \right) (1 + o(1)) \end{aligned}$$

### 3/ Cas multivarie.

Si  $K$  un noyau d'ordre  $r$ , alors  $K = \prod_{i=1}^d K^i$  est un noyau d'ordre  $r$  sur  $\mathbb{R}^d$ .

$K: \mathbb{R}^d \rightarrow \mathbb{R}$  en noyau borne et intégrable tq

$$\int_{\mathbb{R}^d} K(u) du = 1.$$

$$\hat{f}_n(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(x - \frac{X_i}{n}\right),$$

$K$  est un noyau d'ordre  $r$  sur  $\mathbb{R}^d$  si

- \*  $\int_{\mathbb{R}^d} |u^q K(u)| du < +\infty \quad \forall q = r$
- \*  $\int u^q K(u) du = 0 \quad \forall q < r-1$
- \*  $\int u^q K(u) du \neq 0 \quad \forall q = r$

Sous des conditions de régularité sur  $K$  et  $f$ , ainsi que de hypothèses convenable ( $h \rightarrow 0, nh^d \rightarrow \infty$ ), on a :

$$* \hat{f}_n(x) \xrightarrow[n \rightarrow \infty]{L^2} f(x)$$

$$* \mathbb{E} \left[ \int_{\mathbb{R}^d} (\hat{f}_n(x) - f(x))^2 dx \right] \xrightarrow[n \rightarrow \infty]{} 0$$

$$* \sup_{x \in \mathbb{R}^d} |\hat{f}_n(x) - f(x)| \xrightarrow[n \rightarrow \infty]{} 0$$

$$* \int_{\mathbb{R}^d} |\hat{f}_n(x) - f(x)| dx \xrightarrow[n \rightarrow \infty]{} 0$$

En dimension 1 ( $d=1$ ),

$$MISE(h) = \frac{C_1}{nh} + C_2 (h^r)^2 \int \frac{b^{(r)}(x)^2}{r!} dx.$$

En dimension  $d$ ,

$$MISE(h) = \underbrace{\frac{C_1}{nh^d}}_{AMISE} + C_2 h^{2r} + O\left(\frac{h^{2r}}{nh^d} + \frac{1}{nh^d}\right)$$

$$f(x-hu) = f(x) + \sum_{|\alpha|=1}^{r-1} \frac{1}{\alpha!} \frac{\partial^\alpha f(x)}{\partial x^\alpha} (-hu)^\alpha + \sum_{|\alpha|=r} \frac{1}{\alpha!} \frac{\partial^\alpha f(x-chu)}{\partial x^\alpha} (-hu)^\alpha$$

$\tau \in (0, 1)$

Nous supposons que :

- $f \in L^2(\mathbb{R}^d) \cap C^r(\mathbb{R}^d)$  et les dérivées partielles d'ordre  $r$  bornées et de carrés intégrables.
- $K$  est un produit de noyau d'ordre  $r$  sur  $\mathbb{R}^d$  à support compact:  $K(t) = \prod_{i=1}^d K(t_i)$ .

How to choose  $h$ ?

$$h_{cv} = \underset{h}{\operatorname{argmin}} \left[ \underbrace{\int \hat{p}_n^2(x) dx - \frac{2}{n} \sum_{i=1}^n \hat{p}_n^{(i)}(x_i)}_{\text{unbiased estimator of } MISE(h) - \int b^2(x) dx} \right]$$

unbiased estimator of  
 $MISE(h) - \int b^2(x) dx$

These estimations suffer of the curse of dimensionality.

## III - Kernel regression estimator.

$$(X_1, Y_1), \dots, (X_n, Y_n) \in \mathbb{R}^2, \text{ i.i.d.}$$

we want to estimate  $m(x) = \mathbb{E}[Y(X=x)]$ .

$$= \arg \min_{g \in \mathcal{L}^2(X)} \mathbb{E}\{[Y - g(X)]^2\}$$

En supposant que le support de  $X$  est inclus dans  $[0, 1]$ ,

$\mathbb{R}([0, 1]) = \mathcal{L}$ , nous définirons :

$$p \in \mathbb{N}^*, \quad h = \frac{1}{p}, \quad \beta_j = (j h, (j+1) h], \quad 0 \leq j \leq p-1.$$

$$\mathcal{S}_p = \text{vect} \{ \mathbb{I}_{\beta_j} : 0 \leq j \leq p-1 \}$$

$$\text{Ainsi } m_p(x) = \arg \min_{g \in \mathcal{S}_p} \mathbb{E}\{[Y - g(X)]^2\}$$

$$= \arg \min_{\alpha_0, \dots, \alpha_{p-1}} \mathbb{E}\left\{ \left[ Y - \underbrace{\sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X)}_{\psi(\alpha_0, \dots, \alpha_{p-1})} \right]^2 \right\}$$

GPO : Pour  $j$  fixé

$$\frac{\partial \mathbb{E}\{[Y - \sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X)]^2\}}{\partial \alpha_j} = \frac{\partial \mathbb{E}\{[Y - \sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X)]^2\}}{\partial \alpha_j}$$

$\alpha_j$  dérivable  
ou  $\beta_j$  intégrable

$$= \mathbb{E}\left[ \frac{\partial (Y - \sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X))^2}{\partial \alpha_j} \right]$$

$$\partial (Y - \sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X))^2 = Y^2 - 2\alpha_j \mathbb{I}_{\beta_j}(X) Y + \alpha_j^2 \mathbb{I}_{\beta_j}(X)$$

$$\Rightarrow \frac{\partial (Y - \sum_{j=0}^{p-1} \alpha_j \mathbb{I}_{\beta_j}(X))^2}{\partial \alpha_j} = -2\mathbb{I}_{\beta_j}(X) Y + 2\alpha_j \mathbb{I}_{\beta_j}(X)$$

$$= -2\mathbb{E}[\mathbb{I}_{\beta_j}(X) Y] + 2\mathbb{E}[\alpha_j \mathbb{I}_{\beta_j}(X)]$$

$$\text{Ainsi } E \left[ \frac{\partial (Y - \alpha_j \mathbb{1}_{B_j}(x))^2}{\partial \alpha_j} \right] = 0$$

$$\Rightarrow E[\mathbb{1}_{B_j}(x) Y] = \alpha_j E[\mathbb{1}_{B_j}(x)]$$

$$\Rightarrow \alpha_j^* = \frac{E[\mathbb{1}_{B_j}(x) Y]}{E[\mathbb{1}_{B_j}(x)]}$$

$$\text{Donc } \tilde{m}_n(x) = \frac{\frac{1}{nh} \sum_{i=1}^n Y_i \mathbb{1}_{B_j}(x_i)}{\frac{1}{nh} \sum_{i=1}^n \mathbb{1}_{B_j}(x_i)} = \frac{\tilde{f}_n(x)}{\tilde{p}_n(x)} \quad \forall x \in B_j$$

$$* E[(\tilde{f}_n(x) - f(x))^2] = \beta^2(\tilde{f}_n(x)) + \text{Var}(\tilde{f}_n(x))$$

$$\text{or } \beta(\tilde{f}_n(x)) = \tilde{f}(x) \left( h \left( j + \frac{1}{2} \right) - x \right) + \alpha h^2$$

$$\text{Var}(\tilde{f}_n(x)) = \frac{f(x)}{nh} + O\left(\frac{1}{n}\right)$$

$$* E[(\tilde{p}_n(x) - p(x))^2] = \beta^2(\tilde{p}_n(x)) + \text{Var}(\tilde{p}_n(x))$$

$$\text{or } \beta(\tilde{p}_n(x)) = E[\tilde{p}_n(x)] - p(x)$$

$$= E \left[ \frac{1}{nh} \sum_{i=1}^n Y_i \mathbb{1}_{B_j}(x_i) \right] - p(x)$$

$$= \frac{1}{nh} \sum_{i=1}^n E[Y_i \mathbb{1}_{B_j}(x_i)] - p(x)$$

$$= \frac{1}{h} E[Y \mathbb{1}_{B_j}(x)] - p(x)$$

$$= \frac{1}{h} \int Y \mathbb{1}_{B_j}(x) f_{X,Y}(x,y) dx - p(x)$$

???

$$\int Y \mathbb{1}_{B_j}(x) f_{X,Y}(x,y) dx = \int \mathbb{1}_{B_j}(x) p(x,y) dx$$

(1)

$$K(u) = \frac{1}{2} \mathbb{1}_{|u| < 1}$$

$$\Rightarrow K\left(\frac{x-x_i}{h}\right) = \frac{1}{2} \mathbb{1}_{\left|\frac{x-x_i}{h}\right| < 1}$$

$$\left|\frac{x-x_i}{h}\right| < 1 \Leftrightarrow \frac{x-x_i}{h} < 1 \text{ et } \frac{x-x_i}{h} > -1$$

$$\Leftrightarrow -x_i < h-x \text{ et } -x_i > -h-x$$

$$\Leftrightarrow x_i > x-h \text{ et } x_i < x+h$$

$$\Leftrightarrow x-h < x_i < x+h$$

$$\text{Donc } K\left(\frac{x-x_i}{h}\right) = \frac{1}{2} \mathbb{1}_{x-h < x_i < x+h}$$

$$\Rightarrow \tilde{P}_h(x) = \frac{1}{nh} \sum_{j=1}^n Y_j \underbrace{\frac{1}{2} \mathbb{1}_{x-h < X_j < x+h}}_{K\left(\frac{x-X_j}{h}\right)}$$

$$\left. \begin{array}{l} m = \frac{p}{f} \\ \Rightarrow p = m \cdot f \end{array} \right\}$$

$$\hat{P}_h(x) = \frac{1}{nh} \sum_{j=1}^n Y_j K\left(\frac{x-X_j}{h}\right)$$

$$l_h = \hat{P}_h * l = E[\hat{P}_h]$$

$$\begin{aligned} E[\hat{P}_h^{(x)} - l^{(x)}] &= E[\hat{P}_h^{(x)}] - l^{(x)} \\ &= (K_h * l)_h - l^{(x)} \\ &= \int K_h(x-u) l(u) du - l^{(x)} \\ &= \int K(y) l(x-gh) dy - l^{(x)} \end{aligned}$$

$$\int K(y) f(x-hy) dy - f(x) \quad \text{Taylor young}$$

$$= \int K(y) \left[ f(x) + (-hy) f'(x) + \frac{(-hy)^2}{2} f''(x) + o(h^2) \right] dy - f(x)$$

$$= \int K(y) \left[ -hy f'(x) + \frac{(hy)^2}{2} f''(x) + o(h^2) \right] dy$$

$$= h f'(x) \underbrace{\int y K(y) dy}_0 + \frac{h^2}{2} f''(x) \int y^2 K(y) dy + o(h^2)$$

moment d'ordre 2

$$= \frac{h^2}{2} f''(x) \int y^2 K(y) dy + O(h^2) \quad \text{avec le m.f.}$$

$$\begin{aligned} & \int f(u) K_f(x-u) du \\ &= \int m(u) f(u) K_n(u-u) du \end{aligned}$$

De même,

$$V(f_n(x)) = V\left(\frac{1}{nh} \left[ \sum K\left(\frac{x-x_i}{h}\right) \right]\right)$$

$$= \frac{1}{nh^2} V\left(\sum K\left(\frac{x-x_i}{h}\right)\right)$$

$$= \frac{1}{nh^2} \left\{ E\left[\left(\sum K\left(\frac{x-x_i}{h}\right)\right)^2\right] - E\left[\sum K\left(\frac{x-x_i}{h}\right)\right]^2 \right\}$$

avec  $K(\cdot) = K^T(\cdot)$

$$= \frac{1}{nh^2} (Z_h * f)(x) - \frac{1}{n} (K_h * f)(x)$$

$$\bar{m} - m = \frac{\bar{f}}{\bar{f}} - \frac{f}{f} = \bar{f} \left( \frac{1}{\bar{f}} - \frac{1}{f^2} (\bar{f} - f) + \frac{2}{f^3} (\bar{f} - f)^2 \right) - \frac{f}{f}$$

$$\begin{aligned} & + \frac{f}{f^2} (\bar{f} - f) \\ &= \frac{1}{f} (\bar{f} - f) - \frac{f}{f^2} (\bar{f} - f) + \frac{2}{f^3} (\bar{f} - f)^2 \\ &= \frac{1}{f} (\bar{f} - f) - \frac{f}{f^2} (\bar{f} - f) - \frac{f}{f^2} (\bar{f} - f) + \frac{2}{f^3} (\bar{f} - f)^2 \end{aligned}$$

$$\Rightarrow E[\|\bar{m} - m\|^2] = E\left[\left\| \frac{1}{f} (\bar{f} - f) - \frac{f}{f^2} (\bar{f} - f) \right\|^2\right] (1 + o(1))$$